

relazione

July 9, 2026

0.1 Per questi plot è stato usato il dataset native

```
native_df: (3134, 73)
decoys_df: (3134, 73)
all_native_df: (3731, 73)
tot_df: (6268, 74)


physical_plot_df: (62136, 6)
zernike_plot_df: (62136, 6)
roughness_plot_df: (62136, 6)
```


1 Radial distribution functions

Entrambe sono crescenti, quindi al centro del binding site le due proteine tendono ad essere più vicine e a massimizzare la complementarità di forma

Distanza physical sembra avere andamento esponenziale, distanza zernike andamento lineare. In zernike l'ultimo anello ha una diminuzione ma potrebbe essere perché allontanandoci dal centro i residui sono poco interagenti (infatti la distanza fisica è alta) e quindi la superficie di van der waals diventano più piatte.

Se si guarda la distanza radiale in Å la complementarità di forma sembra saturare a circa 20 Å






2 Global metrics


Tutti tranne prodotto scalare hanno delle code per valori grandi, quindi è interessante studiare se le rdf variano significativamente nelle code. Roughness e flatness come ci si può aspettare sono molto correlate, così come gyration radius e raggio del binding site. Quindi per studiare l'andamento delle rdf al variare di queste metriche è sufficiente prenderne una per coppia: prendiamo roughness (perché a differenza della flatness per la roughness si può costruire un'altra rdf che può arricchire l'analisi) e il raggio di girazione (più robusto perché non dipende dalla metodologia con cui si sceglie il binding site e in ottica di un confronto native vs decoys non cambia tra le due categorie, mentre il raggio del binding site può cambiare tra complesso native e decoy) Il prodotto scalare ci conferma che le coppie di punti scelte per calcolare le rdf sono effettivamente orientati in direzioni opposte, seppur non proprio antiparallele (cosa normale vista l'elevata rugosità delle superfici di van der waals)


Global Metrics Histograms



La metrica che più influenza l'andamento funzionale delle RDF è il raggio di girazione: in particolare più è alto (proteine meno globulari) e più la RDF Zernike si appiattisce

RDFs by gyration radius tertiles





3 Problema

Se si guarda la RDF della distanza fisica negli ultimi anelli essa supera i $5\text{\AA}$, anche abbondantemente nell'ultimo anello. Questo è strano, perché i binding site su cui si fa l'analisi sono selezionati affinché ogni punto di una proteina abbia almeno un punto nell'altra a meno di $5\text{\AA}$: vuol dire che il metodo di sampling non sta funzionando bene.

Questo potrebbe essere potenzialmente un problema perché vuol dire che sto considerando anche coppie che in realtà sicuramente non interagiscono e può falsare l'analisi. In particolare nelle RDF con la distanza radiale in angstrom nella zona centrale si mischiano gli anelli centrali dei complessi con raggio del binding site grande e gli ultimi anelli (quelli problematici perché con più coppie non interagenti) dei complessi con raggio del binding site piccolo.

In effetti in questa zona per la RDF physical ho valori a metà tra l'ultimo anello (circa $20\text{\AA}$) e quelli precedenti (più vicini a $5\text{\AA}$), mentre il fatto che dopo $40\text{\AA}$ scende di nuovo fa pensare che gli ultimi anelli dei complessi con binding site grande siano meno problematici dal punto di vista del sampling.


Nella RDF Zernike in questa zona vedo una saturazione, che comincia proprio quando la RDF physical supera i $5\text{\AA}$. Viene da chiedersi se anche questa sia dovuta a questo errore nel sampling.

Inoltre potrebbe influenzare anche altre analisi, precedenti e successive (magari anche il confronto native vs decoys).

Tuttavia se si guarda il violinplot sottostante la situazione è un po' meno critica di quello che appare: anche negli ultimi anelli la maggior parte dei complessi ha valori più vicini a $5\text{\AA}$ (la linea

tratteggiata). Però probabilmente il fatto di avere code molto estese porta ad avere abbastanza outlier da influenzare considerevolmente la media.

Allora la domanda è se sia necessario effettivamente modificare il sampling e rifare le analisi oppure se basta abbandonare la rappresentazione delle RDF tramite media, usando invece dei boxplot o dei violinplot. Visto anche che le distribuzioni di alcuni anelli e bin sono fortemente asimmetriche forse abbandonare la media in favore di questi plot è meglio a prescindere se venga rifatta l'analisi oppure no.




Si vede anche che effettivamente le distribuzioni dopo i 20Å assomigliano molto a quelle dell'ultimo anello.

Inoltre è interessante che alcune distribuzioni sembrano troncate a valori bassi, come se ci fossero dei valori minimi che però sono molto probabili. Questo fenomeno si ripete anche per altre RDF come si vede sotto: se confermato in ottica Zernike e complementarità di forma è interessante perché vuol dire che molti complessi ottimizzano sullo stesso valore in quell'anello/bin.

Intanto riporto anche dei boxplot e dei violinplot anche per le altre RDF. Lo faccio direttamente per il confronto native vs decoys così sotto ogni grafico posso aggiungere qualche commento se noto qualcosa.


3.1 Physical distance

3.1.1 Raggio normalizzato




Nei primi anelli le distribuzioni dei decoys sembrano più simmetriche

3.1.2 Raggio in angstrom




A distanze centrali i decoys hanno distribuzioni ancora più estese dei native. A distanze basse o alte invece le distribuzioni dei decoys sono più compatte




3.2 Zernike distance

3.2.1 Raggio normalizzato



Nei primi due anelli le distribuzioni dei native sembrano quasi essere delle bimodali


3.2.2 Raggio in angstrom




Negli ultimi bin le distribuzioni decoys tendono a distribuzioni uniformi. Forse indica che a quelle distanze gli algoritmi di docking smettono di ottimizzare l'energia e quindi sono come random patches, mentre i native no?

3.3 Roughness

3.3.1 Raggio normalizzato



3.3.2 Raggio in angstrom



I valori minimi di native e decoys sono simili, mentre i valori massimi dei native sono molto più alti, quindi hanno una coda più importante. I decoys hanno il 50% centrale della probabilità concentrato più in basso rispetto ai native

Forse è per queste code che l'andamento della RDF roughness plottato con la media per i decoys

sembra uguale a quello dei native ma traslato verso il basso.

