

tesi

July 9, 2026

0.1 Per questi plot sono stati usati i dataset decoys e native (per quest'ultimo sono stati presi solo i complessi presenti anche in decoys)

```
native_df: (3134, 73)
decoys_df: (3134, 73)
all_native_df: (3731, 73)
tot_df: (6268, 74)
```

1 Radial distribution functions

1.1 Osservazioni qualitative

RDF distanza fisica sono particolarmente sovrapponibili tra native e decoys

RDF Zernike e roughness sono più basse per i decoys (tranne Zernike per $>40\text{\AA}$). RDF Zernike decoy ha andamento meno lineare dei native.

Dopo $30\text{\AA}$ e ancora di più dopo $40\text{\AA}$ le RDF diventano rumorose

La complementarità di forma viene ottimizzata al centro del binding site, non come l'idrofobicità che era ottimizzata intorno a $9\text{\AA}$

1.2 Interpretazione

Gli algoritmi di docking quando generano un decoy riescono comunque a ricostruire la giusta distanza tra le proteine, ma rendono il binding site un po' più piatto e sorprendentemente ottimizzano meglio la complementarità di forma (anche se c'è da tenere conto che più le superfici sono piatte e più è facile avere complementarità di forma, quindi in parte potrebbe essere legato al fatto che la roughness decoy è minore della roughness native)

1.3 Idea

Si potrebbe vedere qual è il valore medio della distanza di Zernike per random patches (lo chiamo Z). Sarebbe interessante per due motivi:

-Potremmo vedere se e quando le RDF raggiungono Z, cioè quando il binding site comincia a diventare simile a random patches e quindi la complementarità di forma non viene più ottimizzata. Magari succede quando le RDF saturano?


-Potremmo definire la metrica complementarità di forma (da sostituire alla distanza di Zernike) come $Z - \text{distanza_zernike}$. In questo modo si avrebbe un andamento inverso a quello attuale,

quindi con valori alti quando la distanza di zernike è bassa, e lo zero corrisponderebbe al caso random patches

physical / native: norm counts 10, real counts 25

physical / decoy: norm counts 10, real counts 25


Funzione di distribuzione radiale della distanza fisica



zernike / native: norm counts 10, real counts 25

zernike / decoy: norm counts 10, real counts 25


Funzione di distribuzione radiale della distanza Zernike



roughness / native: norm counts 10, real counts 25

roughness / decoy: norm counts 10, real counts 25

Funzione di distribuzione radiale della roughness



2 Global metrics


2.1 Raggio di girazione

Come ci si aspettava il raggio di girazione non cambia tra complesso native e complesso decoy.

I terzili del raggio di girazione non sembrano avere un grande effetto sulla differenza tra le RDF native e decoy.

gyration_radius: soglie = 17.0478, 20.6684

Confronto RDF per raggio di girazione su native e decoy




2.2 Roughness

I decoys tendono ad avere roughness più basse, come avevamo visto anche dalla RDF roughness.

Per roughness molto alte la differenza tra RDF native e decoy si appiattisce, anche se a onor del vero i decoys non hanno molta statistica in questa zona


roughness: soglie = 3.13991, 6.63646

Confronto RDF per roughness su native e decoy



In realtà se si guarda il rapporto roughness native / roughness decoy per ogni complesso si vede che ci sono anche molti complessi in cui la roughness del decoy è minore di quella native, ma la distribuzione è sbilanciata verso rapporti >1

Il raggio di girazione non sembra avere effetti significativi sulla mediana della roughness. Forse l'effetto principale è che al crescere del raggio di girazione aumenta la frequenza di complessi in cui la roughness del decoy è molto più piccola della roughness native.



Numero complessi usati nel plot: 3134

Soglie terzili Rg (Å): 17.051139311230344 20.66810326373692


Statistiche rho_n/rho_d per terzile (mediana e IQR):

	n	median	q25	q75
size_class				
low	1045	1.244422	0.986994	1.554072
medium	1044	1.202665	0.965730	1.595058
large	1045	1.308145	0.974662	1.782626

Se invece plottiamo il rapporto in funzione della roughness native vediamo un andamento lineare: più la roughness native è alta e più il decoy tenderà ad avere una roughness in proporzione più bassa. In altre parole la roughness decoy non è proporzionale alla roughness native, aumenta più lentamente

Inoltre è interessante che nel terzile più basso della roughness native abbiamo invece in media che

il decoy mantiene la stessa roughness.



Numero complessi usati nel plot: 3134
Soglie terzili roughness native: 3.0547927303499818 4.351447539876785

Conteggio complessi rispetto alla retta del fit per terzile:

low: sopra=493, sotto=552, uguali=0
medium: sopra=538, sotto=506, uguali=0
large: sopra=455, sotto=590, uguali=0

Statistiche rho_n/rho_d per terzile (mediana e IQR):

	n	median	q25	q75
size_class				
low	1045	0.957769	0.760435	1.136803
medium	1044	1.270316	1.031385	1.508002

large 1045 1.757888 1.398443 2.216226

Poiché nel grafico precedente la roughness native ρ_N compare sia sull'asse x sia al numeratore del rapporto ρ_N/ρ_D , è necessario verificare che l'andamento osservato non sia una conseguenza artificiale della scelta delle variabili.

Per questo motivo è stato costruito un **modello nullo tramite permutazione**. In particolare, i valori di roughness dei decoys ρ_D sono stati permutati casualmente 10000 volte, rompendo quindi la corrispondenza paired tra ciascun complesso native e il relativo decoy. Per ogni permutazione è stato ripetuto il fit lineare:

$$\frac{\rho_N}{\rho_D} = \alpha + \beta \rho_N$$


ottenendo così le distribuzioni nulle dei coefficienti α e β .

I valori dei coefficienti ottenuti dal fit reale risultano esterni alle distribuzioni generate dal modello nullo. Questo indica che la relazione osservata non è spiegabile soltanto dalla presenza di ρ_N su entrambi gli assi, ma riflette una reale dipendenza tra la roughness del native e quella del corrispondente decoy.

Un aspetto particolarmente interessante è che il modello nullo produce in media valori di β maggiori rispetto al fit reale. Questo significa che, quando i decoys vengono associati casualmente ai native, il rapporto ρ_N/ρ_D cresce più rapidamente con ρ_N . In altre parole, nel caso random i native ad alta roughness vengono spesso confrontati con decoys non correlati e mediamente più lisci, producendo artificialmente una differenza native-decoy più marcata.

Nel dataset reale, invece, la pendenza più bassa suggerisce che i decoys non sono geometricamente indipendenti dai rispettivi native: essi conservano parzialmente le caratteristiche strutturali del complesso di partenza. Tuttavia, poiché la pendenza reale rimane positiva, questa conservazione è solo parziale: al crescere della roughness native, i decoys tendono comunque a non riprodurre completamente i valori più elevati di roughness osservati nelle interfacce native.

In sintesi, il risultato suggerisce che i decoys mantengono parte della geometria globale del complesso, ma mostrano una compressione della roughness, perdendo soprattutto la coda ad alta roughness tipica delle strutture native.



Numero complessi usati nel test: 3134
 alpha vero = 0.346571
 beta vero = 0.252327
 alpha permutati: media=0.252494, std=0.018390
 beta permutati: media=0.277596, std=0.004866

2.3 Raggio del binding site

Nel confronto paired tra il raggio del binding site nel native r_N e nel decoy r_D , il fit lineare mostra una relazione del tipo:

$$r_D = a + br_N$$

con intercetta positiva $a > 0$ e pendenza $b < 1$.

La bisettrice:

$$r_D = r_N$$

rappresenta la condizione in cui native e decoy hanno lo stesso raggio del binding site.

Il fatto che la pendenza sia minore di 1 indica che il raggio del binding site nei decoys cresce all'aumentare del raggio native, ma in modo meno che proporzionale. Tuttavia, l'aspetto più importante è che l'intercetta non è nulla. Se il comportamento fosse semplicemente una riduzione proporzionale del raggio nei decoys, ci si aspetterebbe una relazione circa del tipo:

$$r_D = br_N$$


con la retta passante per l'origine. Invece, la presenza di un'intercetta positiva suggerisce che la relazione non sia una semplice sottostima costante, ma una vera **compressione verso valori intermedi**.

In altre parole, il fit non indica che i decoys abbiano sempre un raggio più piccolo dei native. Piuttosto, suggerisce che i decoys tendano a ridurre il range dinamico dei raggi del binding site:

- per valori piccoli di r_N , il termine di intercetta fa sì che r_D possa risultare comparabile o anche maggiore di r_N ;
- per valori intermedi di r_N , native e decoy risultano mediamente simili;
- per valori grandi di r_N , la pendenza $b < 1$ fa sì che r_D cresca meno rapidamente di r_N , portando quindi a una sottostima del raggio nei decoys.

In sintesi, il raggio del binding site appare più conservato rispetto alla roughness, ma mostra comunque una tendenza alla compressione nei decoys: le pose decoy preservano in parte la scala spaziale dell'interfaccia, ma riproducono meno accuratamente i binding site native molto piccoli o molto estesi.

Distribuzione congiunta del raggio del binding site (native e decoy)



Numero complessi usati nel plot: 3134

alpha = 13.102486

beta = 0.477824

3 PCA

3.0.1 Interpretazione della PCA sui profili radiali Zernike

La PCA è stata applicata ai profili radiali della distanza Zernike, considerando insieme sia i complessi native sia i decoys. Ogni complesso è quindi rappresentato da un vettore di 10 valori:

$$g_Z(r_1), g_Z(r_2), \dots, g_Z(r_{10})$$

dove ciascuna componente corrisponde al valore medio della distanza Zernike in uno dei 10 anelli concentrici del binding site.

L'obiettivo della PCA è individuare le principali direzioni di variabilità dei profili radiali, cioè capire quali combinazioni di anelli spiegano maggiormente le differenze tra i complessi.

3.0.2 Prima componente principale: PCA1

La prima componente principale presenta coefficienti positivi per tutti gli anelli, ma è dominata soprattutto dagli anelli più esterni:

$$\text{ring 10 : 0.860}$$

$$\text{ring 9 : 0.447}$$

mentre gli anelli centrali hanno pesi molto più piccoli.

Questo indica che la PCA1 descrive principalmente la variabilità della distanza Zernike nella regione periferica del binding site. In particolare, valori elevati di PCA1 corrispondono a complessi in cui la distanza Zernike è più alta soprattutto negli anelli esterni, cioè nella parte più periferica dell'interfaccia.

Dal punto di vista geometrico, questa componente può essere interpretata come una misura della variabilità della complementarità di forma nella zona esterna del binding site. Poiché una distanza Zernike maggiore indica minore similarità/complementarità tra le patch confrontate, valori alti di PCA1 indicano profili con maggiore dissimilarità Zernike soprattutto alla periferia.

In sintesi:

$$\text{PCA1} \approx \text{contributo periferico della Zernike RDF}$$

oppure, più precisamente:

$$\text{PCA1} \approx \text{variazione degli anelli esterni, soprattutto ring 9-10}$$

3.0.3 Seconda componente principale: PCA2

La seconda componente principale ha coefficienti positivi negli anelli centrali e intermedi, ma tende a diminuire procedendo verso l'esterno, fino a diventare negativa negli ultimi anelli:

$$\text{ring 1 : 0.647}$$

$$\text{ring 2 : 0.520}$$

ring 3 : 0.378

mentre:

ring 9 : -0.023

ring 10 : -0.156

Questo significa che la PCA2 non misura semplicemente un aumento globale della distanza Zernike, ma descrive piuttosto un contrasto tra la regione centrale e la regione periferica del binding site.

Valori alti di PCA2 corrispondono a profili in cui la distanza Zernike è relativamente più alta negli anelli centrali rispetto agli anelli esterni. Al contrario, valori bassi o negativi di PCA2 indicano profili in cui il contributo periferico diventa più rilevante rispetto al core.

Quindi la PCA2 può essere interpretata come una componente di forma radiale, legata al bilanciamento tra core e periferia:

$$\text{PCA2} \approx \text{contrasto centro-periferia}$$

In altre parole, mentre PCA1 è dominata soprattutto dagli anelli esterni, PCA2 descrive se la distanza Zernike è concentrata maggiormente nel centro del binding site oppure spostata verso la periferia.

3.0.4 Interpretazione complessiva

La PCA suggerisce che la principale fonte di variabilità nei profili radiali Zernike non riguarda uniformemente tutti gli anelli, ma è fortemente influenzata dagli anelli periferici, in particolare ring 9 e ring 10.

Questo è importante perché indica che gran parte della variabilità della Zernike RDF deriva dalla parte esterna del binding site. Di conseguenza, eventuali differenze tra complessi possono essere molto sensibili alla definizione del raggio massimo, alla presenza di punti periferici e al modo in cui vengono campionati gli anelli esterni.

La seconda componente, invece, contiene un'informazione più strutturale sulla forma del profilo radiale, perché distingue profili più centrali da profili più periferici.


3.0.5 Separazione tra native e decoys

Poiché la PCA è stata applicata congiuntamente a complessi native e decoys, ci si potrebbe aspettare che, se la Zernike RDF fosse fortemente discriminante, i due gruppi occupassero regioni diverse nello spazio delle prime componenti principali.

Tuttavia, la distribuzione dei punti native e decoy risulta ampiamente sovrapponibile. Questo indica che le principali direzioni di variabilità dei profili Zernike non coincidono con una separazione netta tra pose native e decoys.

In altre parole, la distanza Zernike media per anello, considerata come profilo radiale globale, non sembra essere sufficiente da sola per distinguere chiaramente native e decoys.

Questo non significa necessariamente che l'informazione Zernike sia assente, ma suggerisce che il segnale discriminante sia più sottile. A maggior ragione un tentativo di usare il machine learning è quindi più che giustificato.



Numero complessi usati nella PCA: 6085

Varianza spiegata: [0.37675104 0.26209627]

Trasformazioni dai coefficienti Zernike a PCA1 e PCA2:

	PCA1	PCA2
zernike_ring1_mean	0.065210	0.646901
zernike_ring2_mean	0.057018	0.519833
zernike_ring3_mean	0.057697	0.378357
zernike_ring4_mean	0.051315	0.268476
zernike_ring5_mean	0.049491	0.191985
zernike_ring6_mean	0.061280	0.146326
zernike_ring7_mean	0.087804	0.101852

zernike_ring8_mean	0.180717	0.051801
zernike_ring9_mean	0.447091	-0.023264
zernike_ring10_mean	0.860274	-0.155536